

Stage Master 2

Accélération de simulations numériques fluides par apprentissage statistique

Laboratoire J.-L. Lagrange

Université Côte d’Azur, Observatoire de la Côte d’Azur, CNRS

1 Contexte du stage

Les simulations numériques fluides sont centrales pour comprendre la physique des disques protoplanétaires, berceau des planètes. Un défi est de prendre en compte de manière cohérente les multiples échelles de taille qui sont en jeu pour former des planètes, ce qui nécessite des résolutions spatiales très importantes. Une solution est de résoudre les équations physiques aux grandes échelles et de corriger les erreurs dues à l’absence des petites échelles par des méthodes d’intelligence artificielle.

Nous avons mis en place une méthode de correction automatique de ces erreurs dans des simulations numériques de turbulence. L’approche utilisée, dite « solver-in-the-loop » [1], intègre un réseau de neurones convolutif noté f_θ dans la résolution des équations physiques. A chaque pas de temps t , le réseau corrige l’état calculé par le solveur basse résolution $\mathcal{P}$:

$$\mathbf{u}_{t+1} = \mathcal{P}(\mathbf{u}_t) + f_\theta(\mathcal{P}(\mathbf{u}_t)) \quad (1)$$

Le réseau convolutif est entraîné en déroulant cette équation sur T pas de temps et en comparant les prédictions $\mathbf{u}_t^{\text{pred}}$ aux simulations de référence ramenées à la grille basse résolution $\mathbf{u}_t^{\text{ref}}$. Cette approche permet de retrouver des propriétés statistiques de simulations à haute résolution, telles que le spectre en énergie de la turbulence. Son inconvénient majeur est le couplage entre le code de résolution numérique et le réseau de neurones pendant la phase d’apprentissage : le gradient doit traverser les T pas du solveur.

Ce couplage nécessite entre autres l’utilisation d’un code différentiable (dans notre cas, JAX-CFD en Python/JAX, pour $\mathcal{P}$, associé à la librairie FLAX pour les réseaux de neurones). Au-delà de cette contrainte, cette approche alourdit considérablement la tâche d’apprentissage, en limitant par exemple la taille de l’ensemble d’entraînement.

2 Objectif du stage et étapes

L’objectif de ce stage est de développer une approche de correction fondée uniquement sur les données d’entraînement, sans faire intervenir le code de résolution durant l’apprentissage. La première étape de ce stage consistera donc à construire une base d’apprentissage à partir des simulations de référence $\mathbf{u}_t^{\text{ref}}$ qu’on pourra ensuite enrichir par les méthodes d’augmentation, en exploitant les symétries de l’écoulement. Pour chaque état, on calculera le terme de correction $\mathbf{c}_t = \mathbf{u}_{t+1}^{\text{ref}} - \mathcal{P}(\mathbf{u}_t^{\text{ref}})$.

Le problème se ramène ainsi à une régression supervisée. Cette simplification ouvrira la porte à des architectures plus récentes pour le choix de f_θ . Une attention particulière sera apportée aux choix de la fonction coût d’apprentissage dans laquelle il faudra intégrer des contraintes physiques, comme la conservation de l’énergie. Ces contraintes pourront être introduites dans l’architecture des réseaux et dans les différents coûts d’entraînement.

2.1 Extension selon l'avancement

Soulignons également que cette approche permettra de s'affranchir des limitations du code différentiable actuel et de traiter des cas plus complexes comme le cisaillement en ayant recours à des jeux d'entraînement obtenus grâce à des codes de référence.

Le stage sera effectué dans une équipe mêlant machine learning, mécanique des fluides et astrophysique. Le ou la stagiaire pourra profiter d'un encadrement multiple associant ces différentes compétences. Au-delà de l'encadrement, il ou elle aura accès aux séminaires hebdomadaires du laboratoire et de l'équipe de planétologie.

Compétences

- Machine learning
- Maîtrise de Python
- Intérêt pour la mécanique des fluides et l'astrophysique
- Autonomie et capacité à travailler dans un contexte interdisciplinaire

Contacts

- Héloïse Méheut : heloise.meheut@oca.eu
- André Ferrari : andre.ferrari@univ-cotedazur.fr

Références

- [1] Dmitrii KOCHKOV et al. "Machine learning-accelerated computational fluid dynamics". In : *Proceedings of the National Academy of Science* 118.21 (mai 2021).